

单细胞高维向量近似最近邻检索系统

A Web-based ANN Retrieval Platform for Single-cell Data

软件工程大作业 · 课程答辩

FastAPI

React 19

FAISS · HNSWLIB

RAG

团队 XXX · 2026 年 5 月

目录 Outline

#	章节	关键词
1	项目背景	单细胞测序 · ANN 必要性
2	需求分析	课程要求 · 功能矩阵 · 加分项
3	系统设计	架构 · 技术栈 · 引擎抽象 · 数据模型
4	核心实现	检索流水线 · 关键代码
5	加分功能	多数据集联合 · Adaptive HNSW · RAG
6	实测与交付	性能数据 · 演示截图 · 质量保障 · 总结

1. 项目背景 Background

单细胞测序 (scRNA-seq) 数据特征

- 一次实验可生成 **十万级** 细胞样本，每个细胞数值化为高维向量
- 本项目使用 CZI 公开数据 `liver.h5ad`：**69 032 细胞 × 30 维 PCA 向量**

痛点

- 精确 KNN 在 $N=10^5$ 、 $D=30\sim 512$ 时延迟达数百毫秒，难以支持交互式查询
- 单细胞分析平台普遍依赖 Jupyter 脚本，缺乏面向 Web 的统一检索入口

ANN 的价值

- 在召回率仅损失 $< 0.5\%$ 的前提下，将单次查询从亚秒级压到 **微秒级**
- 配合元数据过滤、可视化、自然语言问答，可承载真实科研场景

2. 需求分析 Requirements


课程核心要求（必做）

模块	核心交付
用户信息	注册 / 登录 / JWT 鉴权 / 管理员角色
数据管理	.h5ad 上传、Scanpy 预处理、向量提取
索引构建	多后端 / 可保存可加载 / 异步任务
查询检索	按 cell_id / 按向量 / 条件过滤 / Top-K
可视化	UMAP 投影、检索结果高亮、性能图表

加分功能（全做）

- 多数据集联合检索：并发 + min-max 归一化 + 重排
- ANN 算法改进：自适应 HNSW（自研后端）
- RAG + 单细胞：自然语言 → 解析 → 检索 → 总结

3. 系统架构总览 Architecture



3.1 技术栈 Tech Stack

层	选型	用途
前端	React 19 · TypeScript · Vite · Ant Design · Zustand · Plotly	SPA · 状态管理 · 交互式可视化
后端	Python 3.12 · FastAPI · SQLAlchemy 2 async · Pydantic v2	异步 REST · ORM · 数据校验
任务队列	ARQ + Redis	索引构建 / 预处理后台任务
数据库	PostgreSQL 17	用户 / 数据集 / 索引 / 检索日志
缓存	Redis 7	查询缓存 + ARQ broker
ANN 引擎	FAISS · HNSWLIB · scikit-learn	5 种后端 (HNSW · IVF-PQ · Brute · Adaptive)
单细胞	scanpy · anndata · numpy · scipy	h5ad 读取 · PCA / UMAP
LLM	DashScope · OpenAI 兼容 · Mock	RAG 自然语言查询
基础设施	Docker Compose · Nginx · GitHub Actions · pre-Commit	部署 · CI · 代码规范

3.2 ANN 引擎抽象 IndexBackend

统一接口

```
IndexBackend (ABC)
├─ name          — 后端标识
├─ build(X, **)  — 构建索引
├─ search(q, k)  — Top-K 检索
├─ save / load   — 持久化
└─ memory_mb()   — 内存估计
```

5 个具体后端 + 工厂 + 缓存

后端	实现库	特点
brute	numpy	精确，作为 ground truth
hnswlib	hnswlib 0.8.0	高召回 + 微秒级延迟
faiss-hnsw	faiss 1.13	OMP 多线程友好
faiss-ivfpq	faiss 1.13	量化压缩，内存极小
adaptive-hnsw	自研	早停 + 升档（加分项）

4. 核心代码：抽象 + 自适应 ef


IndexBackend 抽象

```
class IndexBackend(ABC):
    @property
    @abstractmethod
    def name(self) -> str: ...
    @abstractmethod
    def build(self, vectors: np.ndarray, **params) -> None: ...
    @abstractmethod
    def search(self, query: np.ndarray, top_k: int) -> tuple[np.ndarray, np.ndarray]: ...
    @abstractmethod
    def save(self, path: str) -> None: ...
    @abstractmethod
    def load(self, path: str) -> None: ...
    @abstractmethod
    def memory_mb(self) -> float: ...
```


自适应 HNSW 核心循环（节选）

```
while pending.size > 0:
    self._index.set_ef(int(max(ef, k_query)))
    labels, dists = self._index.knn_query(q[pending], k=k_query)
    if retry == 0: # 首轮：相对距离间隔早停
```


4.1 数据模型 ER



4.2 检索流水线时序



5. 加分项 ①：多数据集联合检索

问题：用户希望"在多个肝脏数据集里一起找相似细胞"

实现要点

1. 路由层 `POST /search/multi-dataset`，接收 `dataset_ids: [int]`
2. 对每个数据集 **并发** 调用 `async_search_by_vector` (`asyncio.gather`)
3. 每个数据集结果做 **min-max 归一化**：`norm = (d - dmin) / (dmax - dmin)`
4. 合并后按 `normalized_distance` 升序，统一 Top-K，并标注 `source_dataset_id`

```
merged.sort(key=lambda x: x["normalized_distance"])
final = merged[:top_k]
for i, item in enumerate(final, start=1):
    item["rank"] = i
```

收益：跨数据集语义可比；并发 $\text{latency} \approx \max(\text{per_dataset})$ ，而非求和。

5. 加分项 ②：自适应 HNSW

动机：固定 `ef_search` 在 query 难度分布不均时浪费算力 / 召回不足。

策略（继承 `HnswlibBackend`，仅重写 `search`）

- 起始 `ef = min_ef (32)`，oversample 多取 8 个候选
- 首轮判稳：相对距离间隔 $gap = (d[k] - d[k-1]) / (d[k-1] - d[0])$ ，越大说明 Top-K 边界越清晰
- 后续轮判稳：与上一轮 Top-K 的集合重合度 `overlap@k`
- 升档：`ef = min(ef * 2, max_ef=512)`；按 query 粒度独立判定，已稳定提前返回

实测 (top_k=10, N=30 000)

指标	hnswlib 固定 ef=64	adaptive-hnsw
p50 / p95 (ms)	0.016 / 0.020	0.045 / 0.057
Recall@10	0.9996	0.9994
mean_ef	64	50.6

5. 加分项 ③：RAG 自然语言查询

流程： `parse_query` → ANN search → `summarize`



三客户端协议化设计 —— 无外网也可演示

6. 实测数据：liver.h5ad

数据集：CZI 儿童肝脏 scRNA-seq, 69 032 细胞 × 30 维 PCA (基准 N=30 000)




索引构建 (10 核 arm64, 单进程)

backend	构建 (s)	内存 (MB)	关键参数
brute	0.000	3.43	—
hnswlib	0.224	7.10	M=16, ef_c=200
faiss-hnsw	0.245	3.43	M=16, ef_c=200
faiss-ivfpq	0.187	0.29	nlist=173, m=10
adaptive-hnsw	0.218	7.10	M=16, ef_c=200

单线程 Top-10 检索延迟与召回

backend	p50 (ms)	p95 (ms)	p99 (ms)	QPS	Recall@10
brute	0.582	0.632	0.650	1 736	1.000
hnswlib	0.016	0.020	0.021	63 158	0.9996

6.1 演示截图集锦



6.1.1 相似细胞检索（真实数据）

可视化

性能评测

RAG

用户管理

按细胞 ID

按向量

多数据集联合

SSE 流式

Ensemble 多后端

* 数据集

liver (#3)

索引 (不选则用最新 ready)

自动选择

* Top-K

10

* 查询细胞 ID

CGACTTCTCCAGGGCT-1_18

过滤器 (可选)

+ 添加过滤条件

发起检索

检索结果

耗时: 1.0 ms


返回数量: 10

后端: hnsplib


距离: l2

Rank	Cell ID	Distance	Metadata
1	TTGCCGTTCTCTTGAT-1_18	29.332634	cell_type: hepatocyte tissue: caudate lobe of liver disease: normal donor_age: >60 years sex: female assay: 10x 3' v2 +50 更多
2	GCACTCTAGCCCAACC-1_3	29.505344	cell_type: mononuclear phagocyte tissue: right lobe of liver disease: normal donor_age: 5-14 years sex: female assay: 10x 5' v2 +50 更多
3	GCGCAGTGTAACATCA-1_18	31.243437	cell_type: hepatocyte tissue: caudate lobe of liver disease: normal donor_age: >60 years sex: female assay: 10x 3' v2 +50 更多
4	ATCTACTCACAACGTT-1_18	31.941196	cell_type: hepatocyte tissue: caudate lobe of liver disease: normal donor_age: >60 years sex: female assay: 10x 3' v2 +50 更多
5	CAACCAACATTTTCAGG-1_18	32.027889	cell_type: hepatocyte tissue: caudate lobe of liver disease: normal donor_age: >60 years sex: female assay: 10x 3' v2 +50 更多
6	CCTAGCTTCCATTCTA-1_18	33.351643	cell_type: hepatocyte tissue: caudate lobe of liver disease: normal donor_age: >60 years

6.1.2 真实 UMAP 可视化（5 万点）



6.1.3 性能评测面板（实测）



6.2 质量保障 Quality

维度	指标
后端测试	35 个 pytest 用例 (auth · datasets · ann · search · evaluation · rag · health), 全部通过
静态检查	ruff lint + format · mypy 类型 · pre-commit 全绿
前端检查	eslint + prettier · TypeScript strict 模式
CI	GitHub Actions 三步流水线: lint → test → build
E2E	Playwright 跑通真实数据全链路, 自动产出 9 张验收截图
Git	25 次 约定式提交 (feat: / fix: / docs: / chore: / build: / test:)
文档	5 篇软件开发文档 (01_项目概述 ~ 05_用户手册) + 性能基准报告 + 答辩 PPT

关键提交节点:

- feat(backend): 自适应 HNSW 后端 + 基准测试脚本 (加分项)
- feat(backend): RAG 自然语言查询模块 (加分项)
- feat(backend): 检索与性能评测模块 (条件过滤 + 多数据集联合 + Recall/QPS/延迟)

6.3 项目交付清单

代码仓库 (GitHub)

- backend/ — FastAPI 后端 (22 个 Python 模块 · 35 测试)
- frontend/ — React 19 + TS 前端 (6 业务页面)
- infra/ — Docker Compose · Nginx · CI
- e2e/ — Playwright 端到端测试
- Makefile — 一键 make up / migrate / test / lint

软件开发文档 (docs/)

文件	内容
01_项目概述.md	背景 · 目标 · 计划
02_需求分析与系统设计.md	用例 · 架构 · 接口 · 数据库 · UI
03_系统测试.md	用例 · 性能测试
04_项目管理.md	分工 · 进度 · 工具

7.1 v1.1 性能优化与新功能总览

v1.0 → v1.1 共新增 26 个 commit · 覆盖 11 个 feat / perf 任务，全部已落地主分支并配套测试。

模块	关键优化	实测收益
缓存	F4 IndexCache 启动预热 · F2 SearchCache (Redis SHA256 key)	首查零冷启动； hit_ratio 实时可监控
索引 / 存储	F3 np.load(mmap_mode='r') · F5 VECTORS_DTYPE=float16 落盘	冷启动 RSS -50% · 磁盘 -50% · Recall@10 仅降 0.4%
算法	P2 numba @njit(parallel=True, fastmath=True) BruteBackend	50k×50 数据 conc=1 p50 1.341 → 0.426 ms (3.15x)
API	F1 /search/batch · F6 /search/by-vector-stream (SSE) · F8 Anthropic Claude Opus	单数据集 N≤50 并发；首条结果即出即推；RAG 三客户端→四客户端
DB	P3 joinedload 消除 N+1 (datasets/index 列表 2→1 SQL)	列表轮询 QPS 翻倍；SQL count 测试守住回归
前端	B1 plotly basic 瘦身 · B2 移动 Drawer · B3 Skeleton · D4 vitest hooks/store 单测	首屏 bundle 显著瘦身；移动端可用；前端单测覆盖率提升

统一节奏：每个 feat/perf 都在同一 commit 内带测试 + 文档同步更新 (docs/06_API接口文档.md 21 → 31 接口)。

7.2 双层缓存: IndexCache + Redis SearchCache

L1 · 进程内 IndexCache (LRU, capacity=4)

- F4 启动预热: lifespan 内查询 `status=ready` 最近 3 条索引一次性 `load`, 消除首查冷启动毛刺。
- `GET /indexes/cache/stats` 返回 `hits / misses / loads / evictions / hit_ratio / cached_index_ids`。
- 单进程内 `asyncio.Lock` 串行化同 `index_id` 并发加载, 避免重复 IO。

```
key = "search:" + sha256(
    f"v1|{index_id}|{top_k}|{cid_or_vechash}|{filters_json}"
).hexdigest()
TTL = settings.SEARCH_CACHE_TTL_SECONDS # 默认 300s
```

```
请求 → IndexCache.get_or_load(index_id, db)
      └─ hit → move_to_end(), 直接返回 backend 实例
      └─ miss → create_backend + load(index_path)
                插入 OrderedDict, 超容量 popitem(last=False)
```

L2 · 跨进程 Redis SearchCache

- F2 接入 `by-id / by-vector / batch` 调用链, 命中走 `cache_hit=True` 直返。
- Redis 不可用 → 优雅降级为透传, 主链路不阻断 (`_errors` 计数器记录异常)。

7.3 算法 / 数据加速: mmap + float16 + numba

F3 mmap 索引加载

- 大底库冷启动 RSS 减半，按需 page-in。
- hnswlib 0.8 load_index 内部已切到 mmap 友好路径，与 F3 协同。

backend	dtype	Recall@10	p95(ms)	QPS(c=1)
brute	fp32	1.0000	0.178	6 356
brute	fp16	1.0000	0.162	6 761
hnswlib	fp32	0.9560	0.038	29 733
hnswlib	fp16	0.9520	0.034	31 125

```
arr = np.load(path, mmap_mode="r", allow_pickle=False)
if arr.dtype == np.float32:
    self._vectors = arr      # 直接复用 memmap, 按页惰性读盘
else:
    self._vectors = arr.astype(np.float32, copy=True)  # float16 → float32 显式 astype
```

F5 float16 落盘（消融，N=5000, d=50, l2)

→ 磁盘 / 冷启动内存 -50%，Recall@10 仅降 0.4%；
与 F3 mmap 正交叠加。

7.4 检索 API 扩展矩阵

#	接口	关键能力	典型用途
F1	POST /search/batch	queries: [{cell_id, vector}] · 1 ≤ N ≤ 50 · asyncio.gather 并发 · 每条独立 SearchCache	评测脚本一次性提交, 全局 total_latency_ms + 逐条 cache_hit
F6	POST /search/by-vector-stream	text/event-stream SSE · event: hit 每 ~20ms 推一条 · 末尾 event: done 汇总 latency_ms	前端"逐条飞入"动画, 消除等待感
F7	POST /search/multi-dataset	并发查多数据集 · min-max 归一化 · 全局 Top-K · 标 source_dataset_id	跨数据集 ensemble (v1.0 加分项 ①)
F8	LLM_PROVIDER=anthropic	AnthropicClient 接入 Claude Opus 4 · 工厂分支 + 失败自动 fallback Mock	RAG parse_query / summarize 第四 种 LLM

F1 batch 请求示例

```
POST /api/v1/search/batch
{
  "dataset_id": 1, "index_id": 7, "top_k": 10,
  "filters": {"cell_type": "hepatocyte"},
  "queries": [
    {"cell_id": "AAACCTGAGAATCT-1"},
    {"vector": [0.12, -0.03, ...]}
```


8.1 v1.2 路线图：6 项加分 × 3 milestone × Pattern B 并行

v1.1.0 之后再启 v1.2 路线图，6 项加分功能全部交付；Pattern B 阶段化并行（milestone 间串行 + milestone 内 2~3 subagent 并行）+ 全程 `/loop 5m` polish。

Milestone	加分项	tag	核心交付
M1 性能呈现升级	C3 recall-QPS 帕累托 + D1 交互仪表盘	v1.2.0-alpha.1	3 sweep REST + <code>/search/with_params</code> + EvaluationPage 双 Tab
M2 算法可视化 + 单细胞独家	D2 HNSW 邻居图 + C5 稀疏感知 ANN	v1.2.0-alpha.2	<code>/indexes/{id}/subgraph</code> + SparseBruteBackend + IndexGraphPage 474 行
M3 跨数据集 + Agent 升级	D7 跨数据集对齐 + D4 LLM Function Calling	v1.2.0	<code>align_datasets()</code> + tool calling Agent loop + RagChatPage 气泡 UI

并行调度成果：6 个 subagent 全部成功（M1 三个 + M2 + M3 各两个），**零文件冲突**——每个 subagent 在分配的模块路径独立工作，主代理只做 schema 对齐 + 收尾。

/loop 5m 监督：累计 9 次 tick 自动跑 pytest + vitest + lint，所有阶段全绿；release 后 `pkill` 干净停止（PID 67513 释放）。

8.2 C3 加分: recall-QPS 帕累托曲线 (ANN-Benchmarks 风格)

后端 sweep 服务

```
async def param_sweep(session, dataset_id,
                      backends, top_k, query_count,
                      ef_search_grid, nprobe_grid):
    # 1. 加载 vectors.npy + 抽 query
    # 2. BruteBackend 作 ground truth
    # 3. 每个 backend build 一次, 复用
    # 4. 扫 ef_search ∈ [16,32,64,128,256,512]
    #    或 nprobe ∈ [4,8,16,32,64,128]
    # 5. _mark_pareto((recall, qps))
    # 6. 落 sweep_runs + sweep_points
```

backend/scripts/sweep_offline.py 提供离线 CLI, 复用同一套纯函数。

真实 liver PCA 30D N=30000 实测 (5 帕累托前沿)

backend	params	recall	QPS	pareto
faiss-hnsw	ef=16	0.9945	123k	✓
faiss-hnsw	ef=32	0.9985	86k	✓
faiss-hnsw	ef=64	0.9990	54k	✓

8.3 D1 + D2 加分：交互仪表盘 + HNSW 邻居图可视化

D1 交互式参数仪表盘

```
@router.post("/search/with_params")
async def search_with_params(req):
    # 1. IndexCache 拿 backend (不重建!)
    # 2. _apply_query_param(ef_search/nprobe)
    # 3. try: search → finally: restore params
    return {hits, effective_params, ignored_params}
```

前端 SweepTab.tsx 三栏：

- 左：滑块 ef_search 8–512 / nprobe 1–256
- 中：Plotly 散点 → onClick 反查回滑块
- 右：debounce 200ms 实时 Top-K 预览

D2 HNSW 邻居图可视化

```
def get_local_subgraph(entry_label, depth, layer, max_nodes):
    # 1. hnswlib.get_neighbors_list(layer=0)
    # 2. BFS 从 entry 展开 depth 跳
    # 3. 边只在 depth_visited[src] < depth 时添加
    # 4. max_nodes 安全截断
    return {nodes, edges, truncated}
```

- 节点 + 边 Plotly 双 trace

8.4 C5 加分：稀疏感知 ANN — 单细胞独家卖点

单细胞 RNA-seq 表达矩阵天然稀疏 (90%+ 基因为 0)。常规走 PCA 降到 30~50 维稠密向量，会丢失稀有基因的强表达信号。

SparseBruteBackend (230 行)

```
# 底库 scipy.sparse.csr_matrix
# 距离 =  $||a||^2 + ||b||^2 - 2 a \cdot b$ 
# 稀疏-稠密点积 BLAS 加速
# 落盘 .npz (scipy.sparse.save_npz)

class SparseBruteBackend(IndexBackend):
    def build(self, vectors):
        self._sparse_vectors = sp.csr_matrix(...)
        self._sq_norms = _row_sq_norms(...)
        if metric == "cosine":
            self._sparse_vectors = _sparse_row_l2_normalize(...)

    def search(self, query, top_k):
        dists = (self._sq_norms +
                 (query**2).sum() -
                 2 * self._sparse_vectors @ query)
        ...
```

数据模型扩展

```
class Dataset(Base):
    vector_format: Literal["dense", "sparse"]
    # alembic 0003: ALTER TABLE...
    # batch_alter_table 兼容 SQLite
    # server_default='dense' 自动回填旧数据
```

8.5 D7 + D4 加分：跨数据集对齐 + LLM Function Calling Agent

D7 跨数据集语义对齐

```
async def align_datasets(session, dataset_ids,
                        method, target_dim):
    # 1. 加载每个 dataset 的 h5ad / 元数据
    # 2. intersect_only: 取基因集交集 →
    #    在统一空间重新 PCA target_dim 维
    # 3. harmony (可选): batch correction;
    #    harmony 缺失时降级 intersect_only
    # 4. 落 data/aligned/{id}/vectors.npy +
    #    cell_map.json
    return aligned_dataset_id
```

POST /datasets/align 触发；multi-dataset 检索新增 aligned_dataset_id 参数走对齐空间单库路径。

```
TOOLS = [search_by_cell_id, search_by_vector,
         list_datasets, filter_cells,
         summarize_results]
```

```
async def chat_with_tools(session, user, query,
                          session_id, max_iterations=5):
    messages = [...]
```

D4 LLM Function Calling RAG Agent

4 个 LLM client (mock/openai/dashscope/anthropic)
全部适配；RagSession / RagMessage 多轮持久化。

8.6 v1.2 工程指标 & Pattern B 并行执行复盘

指标对比 (v1.1.0 → v1.2.0)

维度	v1.1.0	v1.2.0	增量
后端 pytest	76	110	+34 (+45%)
前端 vitest	42	42	0
REST 接口	31+	45+	+14
Alembic 迁移	1	5	+4
ANN 后端数	5	6	+1
累计加分项	11	17	+6
文档章节 (benchmark)	§5.7	§9	+§7/§8/§9

backend pytest 76→110 +34 个新测试 覆盖 sweep / subgraph / sparse / alignment / RAG agent 五类新功能。

Pattern B 并行执行复盘

软件工程大作业

M1 (3 subagent 并行)
α: C3 backend (sweep service)
β: D1 backend (with_params)

关键经验

总结 Conclusion

一个完整的端到端 Web 系统

注册 → 上传 → 预处理 → 多后端索引 → 条件检索 → 可视化 → 参数仪表盘 → HNSW 图
→ RAG Agent

17 项累计加分 (v1.0 三项 + v1.1 八项 + v1.2 六项)

多数据集联合 · 自适应 HNSW · RAG · 8 项 v1.1 perf/feat · 帕累托 · 仪表盘 · HNSW 图 ·
稀疏 ANN · 跨数据集对齐 · LLM Function Calling

实测可量产的性能

微秒级延迟 · 99.96% Recall@10 · 6 万 QPS · 110 个 pytest + 42 个 vitest 全绿

谢谢聆听 · 欢迎提问